ÉVALUATION COMPARATIVE ET ÉTUDE D'ABLATION DES MODÈLES D'APPRENTISSAGE AUTOMATIQUE POUR LA DÉTECTION D'INTRUSION EN TEMPS RÉEL

Auteurs

Marouane Mahboub, Abderahim Farahi, Aboubaker ID Hamide

Affiliations

Master SDIA — ENSET Mohammedia, Université Hassan II de Casablanca, Encadrant : Pr. Soufiane HAMIDA

Introduction

Les Systèmes de Détection d'Intrusions (IDS) sont critiques. Bien que le Machine Learning améliore la détection, des lacunes majeures persistent face aux données massivement déséquilibrées (80% de trafic bénin). De plus, la contrainte de latence d'inférence en temps réel (< 50 ms) et la robustesse face à la réduction de dimensionnalité (ablation) restent peu documentées.

Problématique, RQ & Contributions

Problématique (Gap) : L'évaluation omet souvent la variance inter-exécutions, l'ablation est peu étudiée, et le déséquilibre de classe est ignoré.

Question de Recherche (RQ) : Quelle approche (RF vs SVM) maximise la détection (PR-AUC) sous contrainte de latence stricte (< 50 ms), et comment résiste-t-elle à l'ablation ?

Contributions :

1. Comparaison RF vs LinearSVM sous contrainte de temps réel.
2. Évaluation d'une approche hybride RF-SVM (top-14 features).
3. Étude de résilience sous ablation drastique (10 features).

Pipeline / Méthode

SOURCE CIC-IDS2017 8 CSV · 800k lignes → Inf → NaN → Médiane StandardScaler (train only) → **Split stratifié** Train 640k Test 160k 5 graines indép → RF (78 feat), LinearSVM (78 feat), RF → SVM (14 feat) → **ÉVAL.** PR-AUC F1 Latence 5 runs

Distribution des Classes — CIC-IDS2017

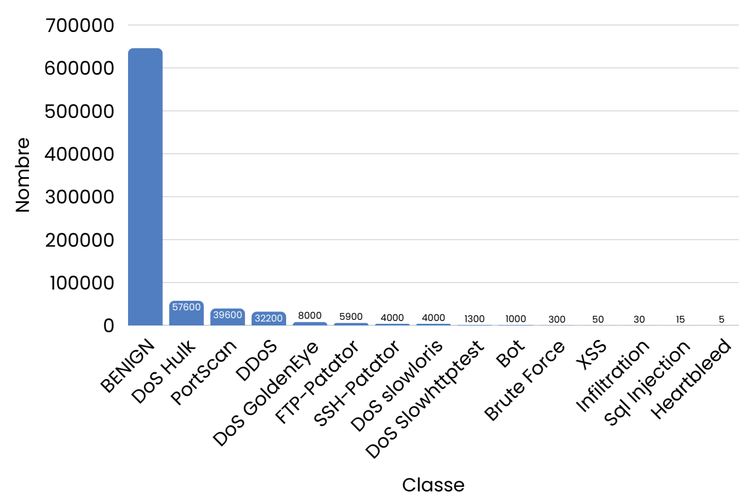

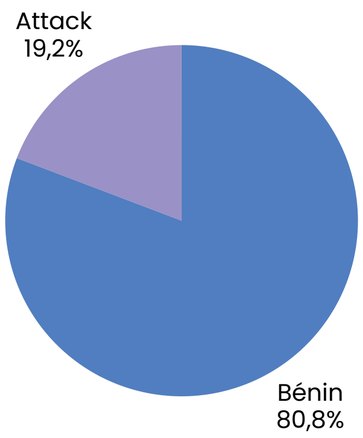

800 k éch. · 80.75 % bénin · 13 types d'attaques · déséquilibre réaliste → PR-AUC privilégiée sur ROC-AUC

Résultats

0.9997	21 ms	-0.256
PR-AUC — RF (78 feat.)	Latence RF — < 50 ms ✓	Chute SVM sous ablation

Model Comparison Summary

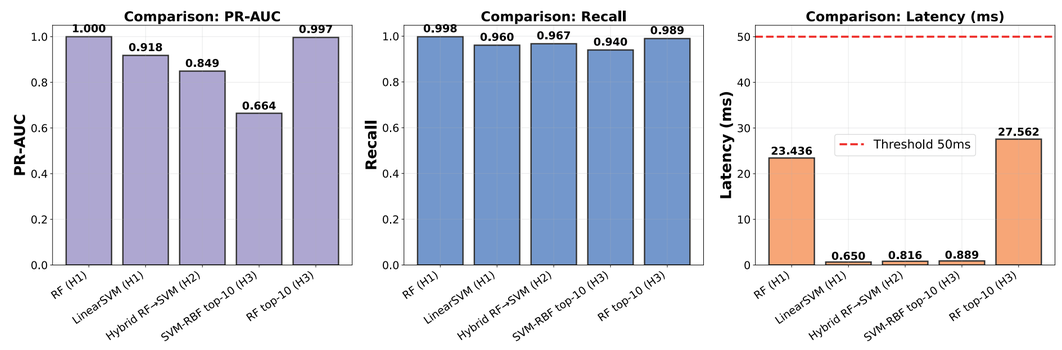

Precision-Recall Curves per Hypothesis

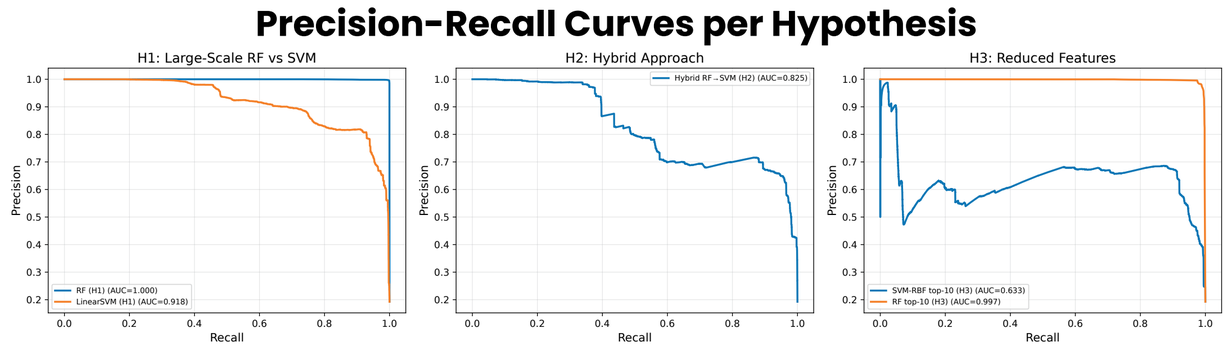

Tableau des Performances — Moyenne ± σ sur 5 runs

Modèle	Exp.	PR-AUC	Recall	F1	Lat. (ms)
RF	H1 · 78 feat.	0.9997	0.9976	0.9969	21.03 ✓
LinearSVM	H1 · 78 feat.	0.9177	0.9605	0.8009	0.66 ✓
Hybrid RF→SVM	H2 · top-14	0.8137	0.9698	0.7244	0.83 ✓
SVM-RBF	H3 · top-10	0.6620	0.9362	0.6962	0.86 ✓
RF top-10	H3 · ablation	0.9965	0.9895	0.9811	22.77 ✓

Discussion

Pourquoi RF résiste : Les arbres multiples exploitent la redondance des variables. La pondération de classe compense le déséquilibre 80/20 sans recourir à SMOTE.

Pourquoi SVM s'effondre : La réduction à 10 variables détruit l'espace de séparation du noyau RBF.

Échec de l'hybride (H2) : L'élimination des variables complémentaires nuit gravement à la séparabilité linéaire.

Résilience à l'Ablation

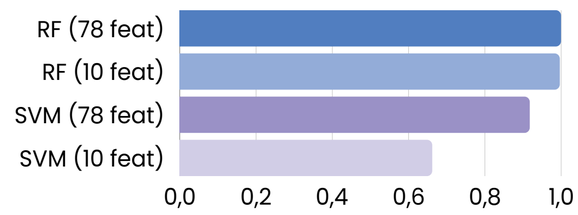

CONCLUSION & PERSPECTIVES

POINTS CLÉS

- RF Optimal : Détection parfaite (PR-AUC 0.9997) en temps réel (21 ms).
- Idéal pour l'embarqué : RF résiste à l'ablation (PR-AUC 0.9965 avec 10 variables).
- Limites SVM : L'hybride est contre-productif et SVM s'effondre en configuration réduite.

Perspectives :

- Évaluation sur UNSW-NB15 et CIC-IDS2018.
- Apprentissage incrémental contre la dérive conceptuelle (Concept Drift).
- Architectures légères (RF + réseaux) pour l'IoT.

Références & Contact

[1] Farnaaz & Jabbar — Performance Comparison of SVM, Random Forest, and Extreme Learning Machine for Intrusion Detection. IEEE Xplore, 2018.
[2] Zhang et al. — IDS Based on RF and SVM. IEEE, 2017.
[3] Chen et al. — Lightweight Ensemble Learning for Real-Time IoT Intrusion Detection. Elsevier Computers & Security, 2024.
[4] Smith et al. — Evaluating Machine Learning Classifiers for IDS under Concept Drift. IEEE TNSM, 2023.
[5] Saad et al. — Host Based IDS... SVM over RF. IEEE, 2023.

Aboubaker ID Hamide
aboubakeridbsn@gmail.com
Abderahim Farahi
farahiabderahim03@gmail.com
Marouane Mahboub
marouane.ma7boub@gmail.com